




Project 4 – Αναφορά



Ανεξάρτητες ερευνητικές εργασίες

Τεχνητή νοημοσύνη στην ογκολογία

Υπολογιστική Ογκολογία

ΕΡΕΥΝΗΤΙΚΗ ΕΡΓΑΣΙΑ

*Αξιολόγηση αλγορίθμων ομαδοποίησης σε δεδομένα γονιδιακών εκφράσεων
διάφορων μορφών καρκίνου από μικροσυστοιχίες DNA*

Έρευνα: Βαβουλίδης Μιλτιάδης – Ζαχαρίας

Συγγραφή: Βαβουλίδης Μιλτιάδης – Ζαχαρίας




Ανεξάρτητες ερευνητικές εργασίες
Βιοϊατρική Μηχανική
Τεχνητή νοημοσύνη στην ογκολογία
Υπολογιστική ογκολογία

-2026-

Αφιερώνεται σε όλους τους αγνοούς ερευνητές που παλεύουν καθημερινά να ανακαλύψουν το μυστικό...

Βαβουλίδης Μιλτιάδης - Ζαχαρίας



ΠΕΡΙΛΗΨΗ

Τα διαρκώς αυξανόμενα περιστατικά καρκίνου ανά την υφήλιο, καθιστούν την ανάγκη για έρευνα υψηλότερη από ποτέ. Η έρευνα αφορά τόσο σε επίπεδο έγκαιρης διάγνωσης όσο και σε επίπεδο αποτελεσματικής θεραπείας. Ευτυχώς, λόγω της εξέλιξης της τεχνολογίας, η ανθρωπότητα αποκτά ολοένα και περισσότερα όπλα για την αντιμετώπιση αυτής της ασθένειας, η οποία βασανίζει ολοένα και πιο έντονα την ανθρωπότητα.

Οι αναδυόμενες τεχνολογίες, καθώς και η εξέλιξη των ήδη υπαρχουσών ποικίλουν. Τα τελευταία χρόνια, λόγω της ραγδαίας εξέλιξης της τεχνητής νοημοσύνης, η ανθρωπότητα επενδύει πολλά στις *in silico* αναλύσεις. Αυτές οι αναλύσεις αφορούν σε πειράματα, τεχνικές και προσομοιώσεις οι οποίες λαμβάνουν χώρα σε εργαστηριακό περιβάλλον χρησιμοποιώντας κατά βάση κατάλληλα αναπτυγμένα λογισμικά. Συγκεκριμένα, αντί για χρήση ενός πραγματικού βιολογικού συστήματος, γίνεται χρήση ενός μοντέλου που προσομοιώνει τη λειτουργία και τα χαρακτηριστικά του βιολογικού συστήματος και μέσω της ακρίβειας και της ταχύτητας που παρέχουν οι σύγχρονες υπολογιστικές συστοιχίες και οι προηγμένοι αλγόριθμοι, η έρευνα επιταχύνεται με ραγδαίους ρυθμούς.

Ένα από τα σημαντικότερα προβλήματα που έως σήμερα αντιμετωπίζουν οι ερευνητές σε *in silico* αναλύσεις αφορά αφενός στην παντελή έλλειψη σχετικών βάσεων δεδομένων, ενώ στην περίπτωση που αυτές υπάρχουν, είναι αρκετές φορές -πρακτικά- ακατάλληλες.

Στην παρούσα ερευνητική εργασία, γίνεται μια προσπάθεια αντιμετώπισης αυτού του φαινομένου. Συγκεκριμένα πραγματοποιείται μια αξιολόγηση ορισμένων αλγορίθμων ομαδοποίησης ώστε να κριθεί εάν είναι ικανοί να θέτουν labels σε unlabeled δεδομένα, δημιουργώντας έτσι -μελλοντικά- χρήσιμα datasets με τεχνητό τρόπο, καθώς ο παραδοσιακός τρόπος (συλλογή στοιχείων ασθενών) γίνεται ολοένα και πιο δύσκολος για λόγους όπως οι περιορισμοί που θέτουν νέοι κώδικες δεοντολογίας και χρήσης προσωπικών δεδομένων (π.χ. GDPR) ή για πρακτικούς λόγους που αφορούν σε πρακτικές δυσκολίες εύρεσης ικανοποιητικά μεγάλου αριθμού δειγμάτων.

Συνοπτικά η ανάλυση χωρίζεται σε διάφορα στάδια, μελετώντας διάφορους αλγορίθμους και αξιολογώντας τους με βάση αυστηρά διεθνή πρότυπα παρόμοιων ερευνών.

Τα αποτελέσματα της παρούσης έρευνας παρουσιάζουν τους περιορισμούς της κάθε μεθόδου εγείροντας ερωτήματα αναφορικά με την προτεινόμενη μελλοντική έρευνα για μια πιο ολιστική προσέγγιση της παρούσης έρευνας.

Συνολικά, η παρούσα έρευνα επιδιώκει να συμβάλει στην παγκόσμια έρευνα για την αποτελεσματικότερη αντιμετώπιση του καρκίνου.



ABSTRACT

Title: Evaluation of Unsupervised Clustering Algorithms on Microarray Gene Expression Data for Breast Tumor Classification under Conditions of Feature Overlap and Sample Imbalance.

Background: The globally increasing incidence of cancer underscores the urgent need for advanced diagnostic and therapeutic research. Driven by rapid innovations in artificial intelligence, *in silico* computational oncology relies heavily on machine learning to process biomedical datasets and bypass structural barriers like stringent privacy regulations (e.g., GDPR) and limited patient sample availability. A critical hurdle within this paradigm is the scarcity of pre-labeled clinical data, presenting an opportunity for unsupervised learning algorithms to automate data annotation and build robust synthetic training sets.

Objective: This study evaluates the capacity of widely used unsupervised clustering algorithms to precisely label data and differentiate between benign and malignant biological profiles without prior training knowledge.

Methodology: Utilizing the Breast Cancer Wisconsin (Diagnostic) Dataset (WDBC) from OpenML (comprising 569 instances: 357 benign and 212 malignant samples characterized by 30 structural nuclear features), a systematic benchmark pipeline was constructed. Raw data underwent rigorous preprocessing, including Winsorization (IQR capping) for outlier mitigation and Standardization transformation (z-score scaling) to neutralize feature scale bias. Three core clustering frameworks were deployed and optimized: K-Means Clustering, Density-Based Spatial Clustering of Applications with Noise (DBSCAN), and Agglomerative Hierarchical Clustering (AHC). Algorithmic performance was validated against the ground-truth annotations using two robust, label-switching-invariant information-theoretic metrics: Adjusted Rand Index (ARI) and Normalized Mutual Information (NMI).

Results: Empirical evaluations revealed distinct trade-offs in structural assumptions and processing efficiency. The DBSCAN algorithm experienced a total catastrophic failure, completely underperforming across the entire parameter tuning grid (ϵ , $\min_samples$); it failed to isolate exactly two clean clusters due to varying feature densities and high-dimensional space sparsity. Conversely, centroid-based and connectivity-based methods yielded reliable results. The AHC algorithm (utilizing Ward's linkage) marginally outperformed K-Means, delivering an ARI of 0.6886 and NMI of 0.5679, compared to the optimized K-Means ($n_init=1$) metrics of ARI = 0.6766 and NMI = 0.5586. Across both functional models, NMI scores were noticeably suppressed relative to ARI values, a divergence mathematically attributed to boundary cluster overlapping and the inherent class sample imbalance, which penalizes cluster entropy and purity. While K-Means proved computationally superior for standalone deployment (0.18s vs 0.52s execution time), its



extensive hyperparameter tuning phase (13.76s) negated this advantage over AHC on sample sizes of this scale.


Conclusion: Both Agglomerative Hierarchical Clustering and K-Means demonstrate moderate-to-high efficacy for automated data labeling in clinical workflows, whereas standalone density-based models like DBSCAN are fundamentally unsuited for this profile of biomedical data. To achieve complete clinical viability, future research should integrate dimensional reduction strategies, expand evaluation across diverse multi-cancer microarrays, and validate downstream performance by feeding cluster-generated labels into supervised learning classifiers.

Keywords: Computational Oncology, Unsupervised Learning, K-Means, Agglomerative Hierarchical Clustering, DBSCAN, Class Imbalance, Data Annotation



Πίνακας περιεχομένων

ΕΙΣΑΓΩΓΗ	7
ΤΕΧΝΙΚΗ ΑΝΑΛΥΣΗ	9
Τα δεδομένα που χρησιμοποιήθηκαν	10
Προεπεξεργασία δεδομένων.....	12
Αλγόριθμοι ομαδοποίησης	14
K-Means Clustering.....	15
Density-Based Spatial Clustering of Applications with Noise (DBSCAN)	18
Agglomerative Hierarchical Clustering	21
Μετρικές αξιολόγησης αλγορίθμων	24
Adjusted Rand Index.....	25
Normalized Mutual Information.....	26
Σύγκριση μετρικών αξιολόγησης.....	27
ΠΕΙΡΑΜΑΤΙΚΑ ΑΠΟΤΕΛΕΣΜΑΤΑ.....	28
Χρόνος εκτέλεσης αλγορίθμων	29
K-Means Clustering	30
DBSCAN	32
Agglomerative Hierarchical Clustering	34
ΣΥΜΠΕΡΑΣΜΑΤΑ.....	35
ΠΡΟΤΕΙΝΟΜΕΝΗ ΜΕΛΛΟΝΤΙΚΗ ΕΡΕΥΝΑ.....	36



ΕΙΣΑΓΩΓΗ

Ο καρκίνος είναι μια ομάδα ασθενειών που χαρακτηρίζονται από ανώμαλη και μη ελεγχόμενη ανάπτυξη κυττάρων σε μια περιοχή ή όργανο. Αρκετές φορές, αυτή η ανάπτυξη δεν περιορίζεται μόνο σε μια περιοχή ή σε ένα όργανο τοπικά, αλλά εξαπλώνεται και σε άλλες. Η ιδιότητα αυτή ονομάζεται μετάσταση και αξιολογείται ως μια από τις κύριες αιτίες για τις οποίες ο καρκίνος είναι θανατηφόρος.

Στην σημερινή εποχή, είναι γνωστοί περισσότεροι από 100 τύποι καρκίνου που επηρεάζουν τον άνθρωπο, με διαφορετικά χαρακτηριστικά και διαφορετικά ποσοστά θνησιμότητας αποτελώντας μια από τις συχνότερες αιτίες θανάτου των ανθρώπων σε παγκόσμιο επίπεδο. Σύμφωνα με τα τελευταία δεδομένα, που προέρχονται από τον Παγκόσμιο Οργανισμό Υγείας (Π.Ο.Υ.), ετησίως, ο καρκίνος είναι η αιτία από την οποία νοσούν και πεθαίνουν περίπου 11.000.000 άνθρωποι, ποσοστό που αντιστοιχεί περίπου στο 20% επί των συνολικών θανάτων.

Τα παραπάνω νούμερα, καθιστούν τον καρκίνο ως την 2η συχνότερη αιτία θανάτου παγκοσμίως αφήνοντας τον πίσω μόνο από τις καρδιαγγειακές ασθένειες. Αφενός, με μια βαθύτερη μελέτη, διαπιστώνεται ότι η πληθώρα των θανάτων από καρδιαγγειακά νοσήματα αφορά σε περιστατικά άνω των 70 ετών ενώ του καρκίνου όχι. Αυτό οδηγεί στο τρομακτικό συμπέρασμα ότι ο καρκίνος, σε ηλικίες κάτω των 70 ετών είναι η πρώτη αιτία θανάτου παγκοσμίως. Αφετέρου, παρατηρείται αυξητική τάση των περιστατικών καρκίνου τα τελευταία χρόνια. Τα δύο αυτά συμπεράσματα αναδύουν στην επιφάνεια την ανάγκη για άμεση και περαιτέρω κινητοποίηση της επιστημονικής κοινότητας προς την κατεύθυνση της καταπολέμησης του καρκίνου.

Στην συντριπτική πλειοψηφία των καρκίνων, όσο νωρίτερα πραγματοποιείται η διάγνωση, τόσο καλύτερη πρόγνωση δίνεται στον ασθενή, δηλαδή τόσο υψηλότερες είναι οι πιθανότητες επιβίωσης του ασθενούς. Έτσι, κρίνεται απαραίτητη η ενίσχυση της επιστημονικής έρευνας γύρω από το πεδίο της έγκαιρης διάγνωσης.

Το παραπάνω στατιστικό συμπέρασμα έχει προκύψει από διαρκή μελέτη περιστατικών καρκίνου στα οποία ακολουθείται συνήθως η παρακάτω διαδικασία (ή μέρος αυτής) για την διάγνωση τους:

- Κλινική εικόνα:
 - Συμπτώματα: Αδυναμία, αιμόπτυση, ζαλάδες, πόνος
 - Παράγοντες κινδύνου: Κάπνισμα, οικογενειακό ιστορικό
 - Φυσική εξέταση: Μακροσκοπική οπτική εξέταση, τοπική αφή



- Εργαστηριακός έλεγχος:
 - Ανάλυση γενικών βιοδεικτών: Λευκά αιμοσφαίρια
 - Οργανική λειτουργία/επάρκεια: Νεφρικός έλεγχος, Υπατικός έλεγχος
 - Ανάλυση συγκεκριμένων βιοδεικτών: PSA για καρκίνο του προστάτη, CA-125 για καρκίνο των Ωοθηκών, AFP για καρκίνο του ήπατος
- Τεχνικές απεικόνισης:
 - Ακτινογραφία
 - Υπέρηχος
 - Αξονική τομογραφία
 - Μαγνητική τομογραφία
 - Τομογραφία εκπομπής ποζιτρονίων
- Βιοψία/Ιστολογική εξέταση:
 - Βιοψία αφαίρεσης ιστού με χρήση ειδικής βελόνας
 - Βιοψία αφαίρεσης ιστού μέσω τομής με χειρουργικό νυστέρι

Η χρήση των παραπάνω τεχνικών διάγνωσης, αφορά στο πρωτόκολλο που εφαρμόζεται παγκοσμίως στις μέρες μας. Η διαρκής έρευνα, η οποία έχει ως σκοπό την αποτελεσματικότερη διάγνωση του καρκίνου, συχνά έχει ως αποτέλεσμα την αναθεώρηση αυτού του πρωτοκόλλου είτε μέσω ανακάλυψης νέων τεχνικών διάγνωσης είτε μέσω ανανέωσης των υφισταμένων.

Ένα από τα πιο σύγχρονα «όπλα» της ανθρωπότητας ακούει στο όνομα «Βιοϊατρική Μηχανική» (Biomedical Engineering). Η βιοϊατρική μηχανική αποτελεί έναν διεπιστημονικό κλάδο που αφορά στην εφαρμογή αρχών μηχανικής (Στατιστική Ανάλυση, Τεχνητή Νοημοσύνη, Μαθηματική Ανάλυση, Γραμμική Άλγεβρα) σε εφαρμογές υγείας και βιοϊατρικά δεδομένα.

Σε αυτό το πλαίσιο, η παρούσα εργασία εφαρμόζει και αξιολογεί μεθόδους βιοϊατρικής τεχνολογίας με σκοπό να συμβάλει στην παγκόσμια σχετική έρευνα. Συγκεκριμένα, χρησιμοποιώντας δεδομένα από δείγματα (ανθρώπους) που πάσχουν καλοήγη και κακοήγη όγκο του μαστού, αξιολογείται η ικανότητα ορθής ομαδοποίησης τους από 3 ευρέως χρησιμοποιούμενους αλγορίθμους ομαδοποίησης.



ΤΕΧΝΙΚΗ ΑΝΑΛΥΣΗ

Η παρούσα έρευνα αφορά στην μελέτη της ικανότητας ομαδοποίησης δειγμάτων καρκίνου του μαστού σε καλοήγη (benign) και κακοήγη (malignant) μέσω εφαρμογής διάφορων αλγορίθμων ομαδοποίησης.

Συνοπτικά, τα στάδια της έρευνας ακολουθούν τα πιο αυστηρά διεθνή πρότυπα και παρουσιάζονται παρακάτω:

- Ορισμός του labeled dataset
- Αφαίρεση των labels
- Εκτέλεση των αλγορίθμων ομαδοποίησης
- Αξιολόγηση των αποτελεσμάτων με χρήση κατάλληλων μετρικών

Σκοπός της τεχνικής ανάλυσης είναι να δοθεί μια «εσωτερική» και -κατά το δυνατόν- αναλυτική πληροφόρηση σχετικά με:

- Τα δεδομένα που χρησιμοποιήθηκαν
- Τους αλγορίθμους ομαδοποίησης
- Τις μετρικές αξιολόγησης των αλγορίθμων

Για κάθε ένα από τα παραπάνω, γίνεται μια προσπάθεια παρουσίασης του με τέτοιο τρόπο ώστε να γίνονται κατανοητά από ερευνητές όλου του φάσματος αυτού του ερευνητικού πεδίου, δηλαδή τόσο αρχάριους όσο και επαγγελματίες, με χρόνια εμπειρίας στο αντικείμενο.

Τονίζεται ότι λόγω του γεγονότος ότι η ελληνική γλώσσα δεν ακολουθεί τους ρυθμούς ανάπτυξης των τεχνολογιών που αναφέρονται σε αυτήν την έρευνα, η ελληνική ορολογία που χρησιμοποιείται ενδεχομένως να διαφέρει από έρευνα σε έρευνα. Για την βέλτιστη κατανόηση, όπου κρίνεται απαραίτητο, χρησιμοποιούνται και οι αγγλικοί όροι.



Τα δεδομένα που χρησιμοποιήθηκαν

Τα δεδομένα που χρησιμοποιήθηκαν προέρχονται από την ανοιχτή βάση δεδομένων «OpenML» και συγκεκριμένα πρόκειται για το «Breast Cancer Wisconsin (Diagnostics) Dataset (WDBC)» με ID:1510. Παρατίθεται σχετικός υπερσύνδεσμος:

<https://www.openml.org/search?type=data&status=any&qualities.NumberOfClasses=%3D2&tags.tag=cancer&id=1510&sort=runs>

Τα εν λόγω δεδομένα αναφέρονται σε πραγματικά δεδομένα. Συγκεκριμένα, Δέκα χαρακτηριστικά πραγματικών τιμών υπολογίζονται για κάθε έναν από 3 κυτταρικούς πυρήνες, με αποτέλεσμα συνολικά 30 περιγραφικά χαρακτηριστικά. Τα 10 χαρακτηριστικά (με τη σειρά που εμφανίζονται) είναι:

Χαρακτηριστικό	Περιγραφή
Ακτίνα (Radius)	Ο μέσος όρος των αποστάσεων από το κέντρο προς τα σημεία της περιφέρειας του πυρήνα
Υφή (Texture)	Η τυπική απόκλιση των τιμών της κλίμακας του γκρι (gray-scale values)
Περίμετρος (Perimeter)	Το συνολικό μήκος του περιγράμματος του πυρήνα
Εμβαδόν (Area)	Η επιφάνεια που περικλείεται από το περίγραμμα του πυρήνα
Ομαλότητα (Smoothness)	Η τοπική μεταβολή στα μήκη της ακτίνας, δηλαδή πόσο ομαλά ή ακανόνιστα μεταβάλλεται το περίγραμμα
Συμπαγότητα (Compactness)	$(\text{περίμετρος}^2 / \text{εμβαδόν}) - 1.0$
Κοιλότητα (Concavity)	Η ένταση ή η σοβαρότητα των κοίλων τμημάτων του περιγράμματος.
Κοίλα σημεία (Concave points)	Ο αριθμός των κοίλων περιοχών ή εσοχών του περιγράμματος
Συμμετρία (Symmetry)	Ο βαθμός συμμετρίας του σχήματος του πυρήνα
Διάσταση fractal (Fractal dimension)	η «προσέγγιση ακτογραμμής» (coastline approximation) μείον 1, η οποία εκφράζει την πολυπλοκότητα ή την τραχύτητα του περιγράμματος

Συνεπώς, για 3 κυτταρικούς πυρήνες υπολογίζονται:




10 χαρακτηριστικά * 3 πυρήνες = 30 περιγραφικά χαρακτηριστικά


Ο ακριβής μαθηματικός υπολογισμός των παραπάνω χαρακτηριστικών παρουσιάζεται στα παρακάτω papers:

- *W.N. Street, W.H. Wolberg and O.L. Mangasarian. Nuclear feature extraction for breast tumor diagnosis. IS&T/SPIE 1993 International Symposium on Electronic Imaging: Science and Technology, volume 1905, pages 861-870, San Jose, CA, 1993.*
- *O.L. Mangasarian, W.N. Street and W.H. Wolberg. Breast cancer diagnosis and prognosis via linear programming. Operations Research, 43(4), pages 570-577, July-August 1995.*

Συνολικά, το dataset αποτελείται από 569 δείγματα, χωρισμένα σε 357 δείγματα καλοήγη και 212 κακοήγη καρκίνου. Στην ερμηνεία των πειραματικών αποτελεσμάτων, οφείλεται να υπολογιστεί σαν παράμετρος και αυτή η ανισορροπία των δειγμάτων. Παρατίθεται σχετικό διάγραμμα:



Φυσικά, στο dataset, ως τελευταία στήλη, δίνεται η κατηγορία (κλάση) στην οποία ανήκει το κάθε δείγμα.



Προεπεξεργασία δεδομένων

Αρχικά, πρώτου εφαρμόσθει οποιαδήποτε υπολογιστική επεξεργασία, πραγματοποιήθηκε κατάλληλη προεπεξεργασία των δεδομένων. Η προεπεξεργασία δεδομένων κρίνεται απαραίτητη καθώς οι αλγόριθμοι που βασίζονται σε μετρικές απόστασης και, ως εκ τούτου, είναι ιδιαίτερα ευαίσθητοι στη κλίμακα και το εύρος τιμών των χαρακτηριστικών. Σκοπός της εφαρμογής της προεπεξεργασίας των δεδομένων είναι η -κατά το δυνατόν- επιτυχία υψηλότερης αντικειμενικότητας και αμεροληψίας στα αποτελέσματα των αλγορίθμων.

Συγκεκριμένα, εφαρμόστηκε:

- Διαχείριση ακραίων τιμών (Outliers Handling):

Η διαχείριση ακραίων τιμών αποτελεί ένα βασικό στάδιο της προεπεξεργασίας δεδομένων. Η μέθοδος που επιλέγεται από τον ερευνητή εξαρτάται πάντα από την εκάστοτε εφαρμογή.


Στην συγκεκριμένη περίπτωση επιλέχθηκε ο μετασχηματισμός (transform) των ακραίων τιμών και η ενσωμάτωση αυτών στα υπόλοιπα δεδομένα. Συγκεκριμένα, στην παρούσα έρευνα εφαρμόστηκε η μέθοδος IQR capping ή Winsorization. Σε αυτή την μέθοδο, αντί να διαγραφούν τα δείγματα τα οποία περιέχουν ακραίες τιμές (το οποίο ενδεχομένως να οδηγήσει σε απώλεια χρήσιμης πληροφορίας), επιλέγεται να ενσωματωθούν σε ένα εύρος τιμών που ορίζεται από 2 τιμές lower bound και Upper bound.

Υπολογιστικά, αυτό που εφαρμόζεται σε κάθε στήλη (χαρακτηριστικό) είναι:

- Υπολογισμός Q1 (25th percentile): Η τιμή κάτω από την οποία υπάρχει το 25% των δεδομένων.
- Υπολογισμός Q3 (75th percentile): Η τιμή πάνω από την οποία υπάρχει το 75% των δεδομένων.
- Υπολογισμός IQR ($Q3 - Q1$): Το εύρος εντός του οποίου υπάρχει το 50% των δεδομένων.
- Υπολογισμός ενός κατωφλίου «φράχτη». Συνήθως η τιμή του ορίζεται να είναι ίση με 1.5 (rule of thumb for outliers)
- Υπολογισμός Lower Bound = $Q1 - (1.5 * IQR)$.
- Υπολογισμός Upper Bound = $Q3 + (1.5 * IQR)$.

Έπειτα, για κάθε ακραία τιμή:

- Αν μια τιμή είναι μικρότερη από το lower bound, της αναθέτει την τιμή του lower bound.



- Αν μια τιμή είναι μεγαλύτερη από το upper bound, της αναθέτει την τιμή του upper bound.
- Αν μια τιμή, είναι εντός του εύρους αυτού, την αφήνει όπως έχει.

- Scaling:

Η εφαρμογή scaling στα δεδομένα αποτελεί και αυτή ένα βασικό στάδιο της προεπεξεργασίας δεδομένων. Όπως και πριν, η μέθοδος που επιλέγεται από τον ερευνητή εξαρτάται πάντα από την εκάστοτε εφαρμογή.

Στην συγκεκριμένα περίπτωση επιλέχθηκε η εφαρμογή της μεθόδου της τυποποίησης (Standardization).

Υπολογιστικά, αυτό που εφαρμόζεται σε κάθε στήλη (χαρακτηριστικό) είναι:

- Υπολογισμός της μέσης τιμής όλων των δειγμάτων (μ).
- Υπολογισμός της τυπικής απόκλισης όλων των δειγμάτων (σ).
- Εφαρμογή scaling σε κάθε ένα χαρακτηριστικό x σύμφωνα με την παρακάτω εξίσωση:

$$z = \frac{x - \mu}{\sigma}$$

Όπου:

- **z**: Η νέα τιμή του χαρακτηριστικού.
- **x**: Η αρχική τιμή του χαρακτηριστικού.
- **μ** : Η αρχική μέση τιμή των δειγμάτων του x χαρακτηριστικού.
- **σ** : Η αρχική τυπική απόκλιση των δειγμάτων του x χαρακτηριστικού.

Διαισθητικά, αυτός ο μετασχηματισμός πραγματοποιεί τα παρακάτω:

- Αφαίρεση της μέσης τιμής μ : Μετατοπίζει τα δεδομένα με τέτοιο τρόπο έτσι ώστε το κέντρο τους να βρίσκεται στο (0,0).
- Διαίρεση με την τυπική απόκλιση σ : Πρακτικά αυτό εφαρμόζει ένα zoom in/zoom out ομοιόμορφα.

Τονίζεται ότι η εφαρμογή αυτής της μεθόδου διατηρεί την αρχική αναλογία τιμών μεταξύ των χαρακτηριστικών του dataset.



Αλγόριθμοι ομαδοποίησης

Στην εν λόγω έρευνα, μελετάται και αξιολογείται η ικανότητα ομαδοποίησης δεδομένων από τους παρακάτω αλγόριθμους:

- K Means Clustering
- Density-Based Spatial Clustering of Applications with Noise (DBSCAN)
- Agglomerative Hierarchical Clustering

Οι αλγόριθμοι αυτοί, αποτελούν χαρακτηριστικά παραδείγματα ευρέως χρησιμοποιούμενων αλγορίθμων σε εφαρμογές μη επιβλεπόμενης μάθησης (unsupervised learning) και δη σε εφαρμογές ομαδοποίησης (clustering) δεδομένων.

Σκοπός της εφαρμογής τους είναι η αξιολόγηση τους και η εξαγωγή τόσο συγκριτικών όσο και εξατομικευμένων συμπερασμάτων.

Παρακάτω, παρουσιάζονται αναλυτικά η αρχή λειτουργίας του καθενός, τα πλεονεκτήματά του καθώς και τα μειονεκτήματά του.



K-Means Clustering

Ένα μοντέλο K-Means Clustering, είναι ένας τύπος αλγορίθμου ομαδοποίησης που χρησιμοποιείται ευρέως σε εφαρμογές μη επιβλεπόμενης μάθησης για ομαδοποίηση δεδομένων. Συγκεκριμένα, αποτελεί τον πλέον γνωστό αλγόριθμο για σχετικές εφαρμογές.

Γενικά, ο K-Means είναι ένας centroid-based (υποθέτει ότι τα clusters έχουν ένα κεντρικό σημείο), επαναληπτικός (iterative) και διαχωριστικός (partitional) αλγόριθμος. Ο κύριος στόχος του είναι η ελαχιστοποίηση της διακύμανσης (variance) εντός κάθε cluster.


Τα κυριότερα, τεχνικά, χαρακτηριστικά ενός τέτοιου μοντέλου είναι:

- **Κριτήριο βελτιστοποίησης (Optimization Criterion / Objective Function):** Ο K-Means μαθηματικά ελαχιστοποιεί το άθροισμα των τετραγωνικών διαφορών εντός του cluster (Within-Cluster Sum of Squares (WCSS)) το οποίο είναι γνωστό ως και αδράνεια (inertia). Αυστηρώς μαθηματικά, υπολογίζεται από την παρακάτω εξίσωση:

$$\operatorname{argmin}_s \sum_{i=1}^k \sum_{x \in S_i} \|x - \mu_i\|^2$$

Όπου:

- **k:** Ο αριθμός των clusters
 - **S_i:** Το set των σημείων (data points) που ανατίθενται στο cluster i
 - **μ_i:** Το κεντροειδές (centroid) ή μέσο διάνυσμα (mean vector) των σημείων στο S_i
 - **|| x - μ_i ||²:** Το τετράγωνο της Ευκλείδειας απόστασης μεταξύ ενός σημείου x και του ανατεθέντος κεντροειδούς.
- **Ο αλγόριθμος του Lloyd:** Ο K-Means χρησιμοποιεί μια αυστηρώς εναλλασσόμενη διαδικασία οπτικοποίησης:
 - **Αρχικοποίηση (Initialization):** Διάλεξε k αρχικά κεντροειδή.
 - **Ανάθεση σε κεντροειδές (Assignment step):** Ανάθεσε το κάθε σημείο στο εγγύτερο κεντροειδές, χρησιμοποιώντας την ευκλείδεια απόσταση.
 - **Αναβάθμιση κεντροειδούς (Update step):** Υπολόγισε τα νέα κεντροειδή όλων των σημείων που έχουν ανατεθεί σε κάθε cluster.
 - **Σύγκλιση (Convergence):** Επανάλαβε την ανάθεση και την αναβάθμιση μέχρις ότου τα κεντροειδή σταματήσουν να μετατοπίζονται ή μέχρις ότου ο αριθμός των μέγιστων επαναλήψεων (παράμετρος του μοντέλου που ορίζεται από τον ερευνητή) επιτευχθεί.



- **Παράμετροι:**

- **Αριθμός clusters:** Ο αριθμός των clusters στους οποίους ομαδοποιούνται τα δεδομένα.
- **Init='k-means++':** Μια μέθοδος βελτιστοποίησης η οποία «απλώνει» τα αρχικά κεντροειδή, έτσι ώστε να επιταχυνθεί η σύγκλιση και να αποφευχθούν φαινόμενα εντοπισμού τοπικών ελαχίστων.
- **n_init:** Ο αριθμός των φορών τις οποίες θα εκτελεστεί ο αλγόριθμος με διαφορετικά αρχικά κεντροειδή (επιλέγεται η καλύτερη εκτέλεση με βάση την αδράνεια).

Τα σημαντικότερα πλεονεκτήματα ενός τέτοιου μοντέλου παρουσιάζονται παρακάτω:


- **Υπολογιστική αποδοτικός (Computational efficient):** Παρουσιάζει γραμμική συσχέτιση μεταξύ των υπολογιστικών απαιτήσεων του αλγορίθμου και του μεγέθους του dataset. Στην διεθνή βιβλιογραφία αναφέρεται ως $O(n*k*d)$ πολυπλοκότητα, όπου «n» είναι ο αριθμός των δειγμάτων, «k» ο αριθμός των clusters και «d» ο αριθμός των χαρακτηριστικών του dataset.
- **Βέβαιη σύγκλιση (Guaranteed convergence):** Ο αλγόριθμος είναι αποδεδειγμένο μαθηματικά ότι πάντοτε συγκλίνει σε μια λύση (ακόμα και αν αυτή αποτελεί τοπικό και όχι ολικό ελάχιστο).
- **Εύκολα ερμηνεύσιμος (Easy interpretation):** Τα clusters που δημιουργούνται είναι εύκολα να ερμηνευθούν καθώς κάθε cluster χαρακτηρίζεται διακριτά από ένα κεντροειδές.
- **Εύκολη προσαρμογή σε καινούργια δεδομένα (Adapts well to new data):** Υπάρχει η δυνατότητα να ανατεθούν καινούργια δεδομένα σε ένα ήδη υπάρχουν cluster απλώς υπολογίζοντας την απόσταση του από το ήδη υπάρχον κεντροειδές, χωρίς ολόκληρη την εκτέλεση του μοντέλου.

Τα σημαντικότερα μειονεκτήματα ενός τέτοιου μοντέλου παρουσιάζονται παρακάτω:

- **Άκαμπτες γεωμετρικές υποθέσεις (Rigid geometric assumptions):** Ο αλγόριθμος αυτός υποθέτει ότι τα clusters είναι σφαιρικά (κυρτά) και έχουν παρόμοια πυκνότητα. Αυτό συμβαίνει καθώς βασίζεται αυστηρώς στην ευκλείδεια απόσταση από ένα κεντρικό σημείο, με αποτέλεσμα να αποτυγχάνει έντονα σε μη σφαιρικά, μη κυρτά ή σύνθετα δεδομένα.



- **Το δίλλημα της παραμέτρου k (The k parameter dilemma):** Η παράμετρος k (αριθμός των clusters) πρέπει να οριστεί πριν την εκτέλεση του αλγορίθμου. Αυτό είναι άκρως προβληματικό σε περιπτώσεις όπου δεν υπάρχει καμία a-priori γνώση της κατανομής/δομής των δεδομένων.
- **Ευαίσθητος σε ακραίες τιμές (Sensitive to outliers):** Λόγω της μαθηματικής του φύσης, η παρουσία ακραίων τιμών (ακόμη και ενός) συνήθως επηρεάζει σημαντικά την απόδοσή του.
- **Ευάλωτος σε τοπικά ελάχιστα (Vulnerable in local minima):** Ο αλγόριθμος είναι ευάλωτος ως προς τη σύγκλιση σε τοπικό ελάχιστο, καθώς εξαρτάται σε πολύ μεγάλο βαθμό από την αρχικοποίηση των κεντροειδών.




Density-Based Spatial Clustering of Applications with Noise (DBSCAN)

Ένα μοντέλο DBSCAN, είναι ένας τύπος αλγορίθμου ομαδοποίησης που χρησιμοποιείται και αυτός ευρέως σε εφαρμογές μη επιβλεπόμενης μάθησης για ομαδοποίηση δεδομένων.

Γενικά, ο DBSCAN είναι ένας density-based αλγόριθμος. Συγκεκριμένα, καθορίζει τα clusters ως συνεχείς (continuous), πυκνές (dense) περιοχές, χωρισμένες από περιοχές με μικρή πυκνότητα, τις οποίες χαρακτηρίζει ως «θόρυβο» (noise).

Τα κυριότερα, τεχνικά, χαρακτηριστικά ενός τέτοιου μοντέλου είναι:

- **Ταξινόμηση των δειγμάτων (Classification of points):** Ο DBSCAN σκανάρει το dataset και ταξινομεί κάθε σημείο σε μια από τις παρακάτω 3 κατηγορίες:
 - **Σημεία πυρήνα (Core points):** Ένα σημείο χαρακτηρίζεται ως σημείο πυρήνα εάν υπάρχουν τουλάχιστον «min_samples» εντός ακτίνας «eps» γύρω από αυτό (συμπεριλαμβανομένου και του ίδιου του εαυτού του). Αυτά τα σημεία σχηματίζουν το εσωτερικό του cluster.
 - **Οριακά σημεία (Border points):** Ένα σημείο χαρακτηρίζεται ως οριακό σημείο εάν υπάρχουν λιγότερα από «min_samples» εντός της ακτίνας «eps» γύρω από αυτό, αλλά αυτό βρίσκεται εντός της γειτονιάς ενός υπάρχοντος σημείου πυρήνα. Αυτά τα σημεία σχηματίζουν τα εξωτερικά όρια ενός cluster.
 - **Θορυβώδη σημεία (Noise points -1):** Κάθε σημείο που δεν ανήκει σε καμία από τις παραπάνω κατηγορίες.
- **Τα αλγοριθμικά βήματα:**
 - **Βήμα 1^ο:** Διάλεξε αυθαίρετα ένα σημείο που δεν έχει διαλεχθεί έως τώρα. Υπολόγισε τις γειτονικές του αποστάσεις χρησιμοποιώντας μια μετρική απόστασης (συνήθως είναι Ευκλείδεια απόσταση) ώστε να ελεγχθεί εάν ταξινομείται ως σημείο πυρήνα.
 - **Βήμα 2^ο:** Αν είναι σημείο πυρήνα, ξεκινάει ένα καινούργιο cluster. Ο αλγόριθμος εξαπλώνει (expand) αναδρομικά το cluster, προσθέτοντας όλα τα σημεία εντός της «eps» γειτονιάς του. Σε περίπτωση που γειτονικά σημεία αποτελούν σημεία πυρήνα, ενσωματώνεται και αυτών η γειτονιά.
 - **Βήμα 3^ο:** Αν το σημείο δεν είναι σημείο πυρήνα, προσωρινά ταξινομείται ως θόρυβος (θορυβώδες σημείο). Αργότερα δύναται να ταξινομηθεί ως σημείο πυρήνα ή ως οριακό σημείο.
 - **Βήμα 4^ο:** Μετακινείται στο επόμενο σημείο (που δεν έχει διαλεχθεί έως τώρα) και τελειώνει μόνο όταν επισκεφθεί όλα τα σημεία.



- **Παράμετροι:**

- **eps:** Ο μέγιστη απόσταση μεταξύ δύο σημείων ώστε να θεωρούνται «γείτονες».
- **min_samples:** Ο ελάχιστος αριθμός σημείων που απαιτείται σε μια «eps» γειτονιά, ώστε να οριστεί μια πυκνή περιοχή (σημείο πυρήνας).

Τα σημαντικότερα πλεονεκτήματα ενός τέτοιου μοντέλου παρουσιάζονται παρακάτω:


- **Ανακάλυψη αυθαίρετων σχημάτων (Discovery of arbitrary shapes):** Ο αλγόριθμος DBSCAN είναι εξαιρετικός στον εντοπισμό σύνθετων, μη σφαιρικών γεωμετρικών δομών.
- **Δεν απαιτεί a-priori ορισμό του k (No prespecified k needed):** Δεν απαιτείται ορισμός του k εκ των προτέρων καθώς ο αλγόριθμος «εσωτερικά» ανακαλύπτει τον αριθμό των clusters βασιζόμενος στην διάταξη/δομή των δεδομένων.
- **Εσωτερικός εντοπισμός ακραίων τιμών (Built – in Outlier Detection):** Μπορεί να αναγνωρίζει αυτόματα ποια σημεία αποτελούν «κανονικά» μέλη κάποιου cluster και ποια σημεία είναι πιθανός θόρυβος ή ακραίες τιμές (outliers), χωρίς να τα αναγκάζει να ενταχθούν σε κάποιο cluster.
- **Ανεξαρτησία ως προς την σειρά επεξεργασίας των σημείων (Order independent):** Για τα σημεία πυρήνα και τα θορυβώδη σημεία, η ανάθεση των τελικών cluster είναι τελερμινιστική και ανεξάρτητη από την σειρά επεξεργασίας των σημείων. Η αλήθεια είναι ότι ένας αριθμός οριακών σημείων μπορεί να επηρεαστούν και να αλλάξουν κατηγορία με βάση την σειρά επεξεργασίας αλλά αυτός ο αριθμός συνήθως είναι πολύ μικρός.

Τα σημαντικότερα μειονεκτήματα ενός τέτοιου μοντέλου παρουσιάζονται παρακάτω:

- **Αποτυγχάνει σε διαφορετικές πυκνότητες (Fails on varying densities):** καθώς χρησιμοποιεί ένα γενικό, καθολικό «eps» και «min_samples» κατώφλι για όλο το dataset υπάρχει ο κίνδυνος να διαχωρίσει ένα αραιό cluster σε θόρυβο ή να ενώσει πυκνά clusters μεταξύ τους.
- **Η κατάρα των διαστάσεων (Curse of dimensionality):** Καθώς ο αριθμός των χαρακτηριστικών αυξάνεται σημαντικά σε σχέση με τον αριθμό των δειγμάτων, ο χώρος (feature space) γίνεται εκθετικά αραιός. Τα σημεία απομακρύνονται μεταξύ τους καθιστώντας τον υπολογισμό της πυκνότητας ανακριβή. Η εύρεση ενός καθολικού «eps» σε χώρους υψηλών διαστάσεων είναι εξαιρετικά δύσκολο.



-
- **Εξαιρετικά ευαίσθητος ως προς τις παραμέτρους (Extremely sensitive to parameters):** Ακόμη και μια (θεωρητικά) μικρή μεταβολή του «eps» δύναται να επηρεάσει σημαντικά την απόδοση του μοντέλου. Συνήθως απαιτεί αυστηρό tuning (συνήθως με χρήση K-Distance Graph).
 - **Υπολογιστικά απαιτητικός (Computational overhead):** Σε σύγκριση με άλλους αλγόριθμους δυσκολεύεται σημαντικά σε μεγάλα datasets, απαιτώντας συχνά υπολογιστική πολυπλοκότητα της τάξης $O(n^2)$.



Agglomerative Hierarchical Clustering

Ένα μοντέλο Agglomerative Hierarchical Clustering (AHC), είναι ένας τύπος αλγορίθμου ομαδοποίησης που χρησιμοποιείται και αυτός ευρέως σε εφαρμογές μη επιβλεπόμενης μάθησης για ομαδοποίηση δεδομένων.

Γενικά, ο AHC είναι ένας clustering bottom-up, ακολουθιακός (sequential) και connectivity-based αλγόριθμος. Συγκεκριμένα, χτίζει ένα δέντρο από clusters μέσα από επαναλαμβανόμενες ενώσεις (repeatedly merging) μικρότερων group.

Τα κυριότερα, τεχνικά, χαρακτηριστικά ενός τέτοιου μοντέλου είναι:

- **Το δεντρογράμμα (The dendrogram):** Ο αλγόριθμος βασίζεται στην δημιουργία ενός δεντρογράμματος, δηλαδή ενός δέντρου όπου καταγράφονται η ακριβής ακολουθία των ενώσεων και οι αποστάσεις στις οποίες πραγματοποιούνται οι ενώσεις. Δύναται το οριζόντιο «κόψιμο» του δέντρου σε οποιοδήποτε κατώφλι απόστασης, ώστε κατευθείαν να παραχθεί συγκεκριμένος αριθμός clusters (k).
- **Κριτήριο ένωσης (Linkage Criteria):** Ο αλγόριθμος ξεκινάει χρησιμοποιώντας κάθε ξεχωριστό σημείο ως αυτόνομο cluster. Έπειτα, υπολογίζει την απόσταση μεταξύ 2 group και αποφασίζει εάν θα τα ενώσει με βάση το κριτήριο ένωσης. Υπάρχουν πολλά κριτήρια που χρησιμοποιούνται για την ένωση μικρότερων group. Το πλέον χρησιμοποιούμενο είναι το «Ward's Linkage», το οποίο -τεχνικά- ελαχιστοποιεί την διακύμανση εντός του cluster (ακριβώς όπως και ο K-Means). Αυτό το κριτήριο έχει την τάση να εντοπίζει αρκετά σφαιρικά, ίσα σε μέγεθος clusters.
- **Παράμετροι:**
 - **n_clusters:** Ο αριθμός των clusters που θα δημιουργηθούν εάν «κοπεί» το δέντρο σε ένα συγκεκριμένο επίπεδο.
 - **metric (of affinity):** Η μετρική απόστασης που χρησιμοποιείται (π.χ. Ευκλείδεια απόσταση)
 - **linkage:** Το κριτήριο ένωσης που χρησιμοποιείται για τον υπολογισμό των αποστάσεων μεταξύ clusters. (π.χ. ward, complete, average, single)

Τα σημαντικότερα πλεονεκτήματα της τέτοιου μοντέλου παρουσιάζονται παρακάτω:



- **Διαισθητική ερμηνεία (Intuitive and interpretability):** Η δεντρική του δομή παρέχει μια εξαιρετικά ακριβή δυνατότητα οπτικοποίησης αναφορικά με τον τρόπο με τον οποίο ο αλγόριθμος χωρίζει τα δεδομένα σε group.
- **Δεν απαιτεί a-priori ορισμό του k (No prespecified k needed):** Δεν απαιτείται ορισμός του k εκ των προτέρων καθώς ο αλγόριθμος χτίζει το δέντρο ξεκινώντας από 1 cluster έως «n» σε κάθε εκτέλεσή του. Ο ερευνητής επιλέγει το «k» όταν αποφασίζει που θα κόψει το δέντρο μετέπειτα.
- **Εύκαμπτος ως της την μετρική (Distance metric flexibility):** Δύναται η επιλογή από μια ευρεία γκάμα μετρικών αποστάσεων, καθώς ο συγκεκριμένος αλγόριθμος είναι αποδοτικός συχνά με περισσότερες από μια μετρικές.
- **Διαχείριση μη σφαιρικής γεωμετρίας (Handles non-spherical geometry):** Ο συγκεκριμένος αλγόριθμος δύναται να διαχειριστεί μη σφαιρικής φύσεως γεωμετρικές κατανομές των δεδομένων. Συχνά αυτό απαιτεί να οριστεί η παράμετρος linkage ως «Single Linkage».

Τα σημαντικότερα μειονεκτήματα της τέτοιου μοντέλου παρουσιάζονται παρακάτω:

- **Μεγάλες υπολογιστικές απαιτήσεις (Terrible computational scaling):** Η δεντρική του δομή παρέχει μια εξαιρετικά ακριβή υπολογιστική πολυπλοκότητα. Συγκεκριμένα, απαιτεί τον υπολογισμό της μήτρας εγγύτητας (proximity matrix), δηλαδή της πίνακα αποστάσεων μεταξύ όλων των σημείων. Λόγω του γεγονότος ότι συχνά η χρονική του πολυπλοκότητα είναι $O(n^2 \log n)$ ή $O(n^3)$ και η χωρική πολυπλοκότητα είναι $O(n^2)$ τον καθιστά απαγορευτικό για μεγάλα datasets.
- **Αμετάκλητες αποφάσεις (Irreversible decisions):** Ο αλγόριθμος είναι εντελώς άπληστος (greedy). Εάν παρθεί μια απόφαση ένωσης δύο group, δεν υπάρχει δυνατότητα αναίρεσης της απόφασης. Αυτό, μπορεί να εγείρει σοβαρά ερωτήματα αναφορικά με την απόδοση του αλγορίθμου, ειδικά σε περιπτώσεις όπου κάποια οριακή τιμή (outlier) ή θόρυβος οδηγήσει σε ένωση δύο group. Αυτό το σφάλμα, θα μεταφέρεται όσο εκτελείται ο αλγόριθμος.
- **Αδυναμία ομαδοποίησης νέων δεδομένων (No prediction mechanism for new data):** Ο συγκεκριμένος αλγόριθμος δεν έχει τη δυνατότητα να ομαδοποιεί καινούργια δεδομένα



δεδομένου της δέντρου που έχει ήδη χτίσει. Η εισαγωγή νέων δεδομένων απαιτεί την επανεκτέλεση του αλγορίθμου από την αρχή, δημιουργώντας ένα νέο δέντρο (ενδεχομένως τελείως διαφορετικό από το προηγούμενο) εάν ο σκοπός είναι η ομαδοποίηση νέου δεδομένου.

- **Ευαισθησία ως προς τις ακραίες τιμές (Sensitive to outliers):** Μια και μόνο ακραία τιμή, ενδέχεται να προκαλέσει αναστάτωση στην ιεραρχία του δέντρου οδηγώντας τον αλγόριθμο σε μη επιθυμητά αποτελέσματα.



Μετρικές αξιολόγησης αλγορίθμων

Ο πρωταρχικός σκοπός της παρούσης έρευνας αφορά στην αξιολόγηση των αλγορίθμων ομαδοποίησης οι οποίοι χρησιμοποιήθηκαν.

Πρακτικά, καθένας από της αλγορίθμους, με βάση τα ιδιαίτερα εξατομικευμένα χαρακτηριστικά κλήθηκε να αναθέσει στο κάθε δείγμα μια τιμή για την κλάση στην οποία ανήκει. Μια πρώτη σκέψη αναφορικά με κάποια μετρική η οποία θα μπορούσε να χρησιμοποιηθεί για την αξιολόγηση της είναι accuracy.

Στην συγκεκριμένη περίπτωση, αυστηρώς μαθηματικά, ως accuracy, ορίζεται το ποσοστό των ορθώς ομαδοποιημένων δειγμάτων σε κλάσεις. Πρακτικά, αυτό γίνεται με μια αντιπαραβολή και άμεση σύγκριση της πραγματικής κλάσης (true label) του αρχικού dataset, με την ανατεθείσα κλάση (assigned label) μετά την εφαρμογή του κάθε αλγορίθμου.

Η παραπάνω μέθοδος οδηγεί σε εσφαλμένα συμπεράσματα καθώς είναι εγγενώς λανθασμένη. Αυτό συμβαίνει διότι γενικά οι αλγόριθμοι ομαδοποίησης ορίζουν ένα label για την κάθε κλάση, εντελώς ανεξάρτητη με την αρχική. Πρακτικά, υπάρχει καμία διαβεβαίωση ότι υπάρχει κάποια αντιστοιχία/συσχέτιση μεταξύ των true labels και των assigned labels, ούτε και δύναται με κάποιο «φθηνό» μαθηματικό τέχνασμα να δημιουργηθεί. Αυτό συμβαίνει διότι η ανάθεση τιμής στα clusters από της αλγορίθμους γίνεται αυθαίρετα (label permutation/arbitrary labels).

Για τον παραπάνω λόγο, έχουν αναπτυχθεί εξυπνότερες μετρικές αξιολόγησης αλγορίθμων ομαδοποίησης από την απλή accuracy. Οι 2 κυριότερες είναι:

- Adjusted Rand Index (ARI)
- Normalized Mutual Information (NMI)

Ακολουθεί η ανάλυση καθεμιάς από της 2 μετρικές αξιολόγησης η οποία αποσκοπεί στην βέλτιστη ερμηνεία των αποτελεσμάτων που θα προκύψουν από την έρευνα.



Adjusted Rand Index

Η πρώτη μετρική αξιολόγησης μοντέλων ομαδοποίησης είναι η Adjusted Rand Index ή σύντομα ARI.

Διαισθητικά, η ARI μετράει το κατά πόσο 2 σημεία καταλήγουν στο ίδιο group τόσο με βάση τα true labels όσο και με βάση τα assigned labels, δηλαδή πριν και μετά την ομαδοποίηση. Επομένως, μοιάζει να αφορά σχέση μεταξύ σημείων και όχι ονόματα των labels.

Εννοιολογικά, η ARI λειτουργεί ως εξής:

Δεδομένων 2 σημείων υπάρχουν οι παρακάτω 4 περιπτώσεις:

Case	True label	Assigned label	Meaning
1	same	same	correct grouping
2	different	different	correct grouping
3	same	different	split error
4	different	same	merge error

Η ARI μετράει πόσο συχνά η ομαδοποίηση συμφωνεί με την πραγματικότητα σε αυτά τα ζεύγη.

Η μαθηματική εξίσωση η οποία διέπει την λειτουργία της είναι η εξής:


$$ARI = \frac{Index - Expected Index}{Max Index - Expected Index}$$

Στον παρακάτω πίνακα, παρουσιάζεται η ερμηνεία της τιμής της ARI:

ARI Value	Meaning
1.0	Perfect match
0.0	Random Clustering
< 0	Worse than random

Η ARI αποτελεί μια αξιόλογη μετρική καθώς:

- Λειτουργεί αποδοτικά ακόμα και αν τα labels κατά την ομαδοποίηση ανταλλάξουν τιμές.
- Βασίζεται σε δομή ζευγαριών (pairwise structure), πράγμα που την καθιστά εύρωστη.
- Χρησιμοποιείται ευρέως σε ερευνητικά papers.



Normalized Mutual Information

Η δεύτερη μετρική αξιολόγησης μοντέλων ομαδοποίησης είναι η Normalized Mutual Information ή σύντομα NMI.

Διαισθητικά, η NMI μετράει την ποσότητα πληροφορίας των true labels η οποία περιέχεται στα clusters.

Η μαθηματική εξίσωση η οποία διέπει την λειτουργία της είναι η εξής:

$$NMI = \frac{2 * I(Y; C)}{H(Y) + H(C)}$$

Όπου:

- $I(Y; C)$: mutual information (shared information)
- $H(Y)$, $H(C)$: Entropies (Uncertainties)

Στον παρακάτω πίνακα, παρουσιάζεται η ερμηνεία της τιμής της ARI:

NMI Value	Meaning
1.0	Perfect match
0.0	No relationship
between	Partial match

Η NMI αποτελεί μια αξιόλογη μετρική καθώς:

- Λειτουργεί αποδοτικά με διαφορετικό αριθμό clusters.
- Είναι περισσότερο ερμηνεύσιμη ως «αμοιβαία πληροφορία».
- Χρησιμοποιείται ευρέως σε ερευνητικά papers.



Σύγκριση μετρικών αξιολόγησης

Παρακάτω ακολουθεί μια συνοπτική σύγκριση των 2 μετρικών αξιολόγησης.

Αρχικά, δίνεται ο παρακάτω συνοπτικό πίνακας:

Feature	ARI	NMI
Based on pairs	Yes	No
Based on information theory	No	Yes
Penalizes random clustering	Strongly	Moderately
Handles label switching	Yes	Yes
Best for scientific papers	Yes	Yes

Συνοπτικά, διαισθητικά οι 2 μετρικές απαντούν της παρακάτω ερωτήσεις:

- ARI: Τα σημεία ομαδοποιούνται μαζί ορθά;
- NMI: Οι ομάδες (clusters) περιέχουν την σωστή πληροφορία;

Οι 2 μετρικές υπολογίζουν στην ίδια ιδέα, με διαφορετικό τρόπο. Η χρήση και των 2 προσδίδει επιστημονικό κύρος σε σχετικές έρευνες.



ΠΕΙΡΑΜΑΤΙΚΑ ΑΠΟΤΕΛΕΣΜΑΤΑ

Παρακάτω παρουσιάζονται όλα τα πειραματικά αποτελέσματα που προέκυψαν από την έρευνα. Σκοπός της παρουσίασής τους είναι η οπτικοποίηση της εσωτερικής λειτουργίας και κυρίως της απόδοσης των αλγορίθμων τόσο σε εξατομικευμένο όσο και σε συγκριτικό επίπεδο για την ασφαλέστερη και -κατά το δυνατόν- βέλτιστη εξαγωγή ασφαλών και χρήσιμων συμπερασμάτων.

Τα πειραματικά αποτελέσματα παρουσιάζονται για όλους τους αλγορίθμους, για όλες τις μετρικές αξιολόγησης που ήδη έχουν προαναφερθεί καθώς και για ό,τι άλλο κρίθηκε απαραίτητο κατά τη διάρκεια της έρευνας (π.χ. χρόνος εκτέλεσης των αλγορίθμων).



Χρόνος εκτέλεσης αλγορίθμων

Παρακάτω παρουσιάζονται συγκριτικά οι χρόνοι που απαιτήθηκαν για την εκτέλεση των αλγορίθμων ομαδοποίησης. Στόχος είναι ο σχηματισμός μιας εικόνας αναφορικά με τον συμβιβασμό (tradeoff) μεταξύ του χρόνου εκτέλεσης και απόδοσης του κάθε αλγορίθμου.

Αρχικά, παρουσιάζεται ο χρόνος που χρειάστηκε για να γίνει fine tuning το κάθε μοντέλο και έπειτα παρουσιάζεται ο χρόνος εκτέλεσης που απαιτεί κάθε finely tuned μοντέλο.

Στον παρακάτω πίνακα παρουσιάζονται συγκριτικά οι χρόνοι εκτέλεσης που απαιτήθηκαν για να γίνει fine tuning το μοντέλο:

Αλγόριθμος	Χρόνος εκτέλεσης (sec)
K-Means	13.76
DBSCAN	11.49
AHC	(*)

Από την μελέτη του παραπάνω πίνακα προκύπτει ότι η χρονική διάρκεια που απαιτήθηκε για το fine tuning του K-Means είναι υψηλότερη από του DBSCAN.


(*) Τονίζεται ότι στην περίπτωση του Agglomerative Hierarchical Clustering, δεν υπάρχει παράμετρος για fine tuning, καθώς όλες είναι εκ των προτέρων γνωστές.

Στον παρακάτω πίνακα παρουσιάζονται συγκριτικά οι χρόνοι εκτέλεσης που απαιτήθηκαν για να εκτελεστεί το κάθε finely tuned μοντέλο:

Αλγόριθμος	Χρόνος εκτέλεσης (sec)
K-Means	0.18
DBSCAN	(**)
AHC	0.52

Από την μελέτη του παραπάνω πίνακα προκύπτει ότι η χρονική διάρκεια που απαιτείται για την εκτέλεση του μοντέλου AHC είναι υψηλότερη (σχεδόν 3 φορές) από αυτή του K-Means. Αυτή η διαφορά πιθανότατα αναμένεται αν είναι ακόμα υψηλότερη σε μεγαλύτερα datasets.


(**) Τονίζεται ότι κατά την διαδικασία του fine tuning των παραμέτρων του αλγορίθμου DBSCAN, βρέθηκε ότι δεν υπάρχει κανένας συνδυασμός παραμέτρων από τον οποίον προκύπτει μοντέλο με ικανοποιητικά υψηλή απόδοση. Γι' αυτό, δεν δημιουργήθηκε κανένα μοντέλο, επομένως απουσιάζει και ο χρόνος εκτέλεσής του (βλ. πειραματικά αποτελέσματα - DBSCAN).



K-Means Clustering

Παρακάτω παρουσιάζονται όλα τα πειραματικά αποτελέσματα τα οποία προέκυψαν από την μελέτη του αλγορίθμου K-Means.

Αρχικά, επιδιώχθηκε να γίνει fine tuning η παράμετρος n_init . Τα αποτελέσματα της παραπάνω διαδικασίας αποτυπώνονται στο παρακάτω διάγραμμα:



Από το παραπάνω διάγραμμα καθίσταται σαφές ότι η απόδοση του αλγορίθμου δεν επηρεάζεται καθόλου από την μεταβολή της παραμέτρου « n_init », αλλά παραμένει σταθερή. Έτσι, λογικά, για την αξιολόγηση του μοντέλου, ως τιμή της παραμέτρου « n_init » επιλέχθηκε η μικρότερη, δηλαδή η τιμή 1.

Οι τιμές των μετρικών αξιολόγησης, μετά την εκτέλεση του παραπάνω μοντέλου είναι:

- ARI = 0.6766
- NMI = 0.5586

Από τις παραπάνω πειραματικές τιμές προκύπτει ότι το μοντέλο δύναται να χαρακτηριστεί ως «μέτριο προς καλό». Φυσικά, οδηγείται σε ορισμένες αστοχίες, ωστόσο προβαίνει και σε αρκετές ορθές επιλογές.



Ορισμένοι λόγοι οι οποίοι ενδέχεται να επηρεάζουν αρνητικά την απόδοση του μοντέλου είναι οι εξής:

- Τα όρια μεταξύ των clusters δεν είναι απολύτως σαφή, αλλά υπάρχει υπερκάλυψη αυτών (overlapping).
- Η ανισορροπία μεταξύ των δειγμάτων του dataset.

Ο τελευταίος λόγος παρουσιάζει -πράγματι- αρκετό ενδιαφέρον στην παρούσα έρευνα. Συγκεκριμένα η ερμηνεία δίνεται μέσα από την απαντήσεις των 2 παρακάτω ερωτημάτων:

1. Γιατί η ARI είναι υψηλότερη;


Η ARI αξιολογεί ζεύγη data points. Όταν υπάρχει μια πλειοψηφική ομάδα (στην περίπτωση αυτή είναι τα δείγματα καλοήγη όγκου) τότε υπάρχει μεγαλύτερη πιθανότητα τέτοια ώστε 2 τυχαία επιλεγμένα σημεία να ανήκουν και τα 2 σε αυτήν την ομάδα. Εάν ο αλγόριθμος τοποθετήσει επιτυχώς στο ίδιο group την πλειοψηφία της ομάδας μαζί, η ARI τον ανταμείβει ισχυρά καθώς έχει πετύχει να διαχειριστεί ορθώς μεγάλο αριθμό «true positives» ζευγών. Γενικά, η ARI είναι αρκετά ευαίσθητη ως προς το να ομαδοποιηθεί η πλειοψηφική ομάδα των σημείων σωστά.

2. Γιατί η NMI είναι χαμηλότερη;

Η NMI βασίζεται στην εντροπία (αβεβαιότητα). Δεν την ενδιαφέρει το μέγεθος της ομάδας (cluster) όσο η καθαρότητα (purity) τους. Ακόμα και αν λίγα δείγματα από την πλειοψηφική ομάδα «παρεισφρήσουν» στην μειοψηφική ομάδα, η αβεβαιότητα αυτής της ομάδας εκτοξεύεται. Η NMI το τιμωρεί αυτό σημαντικά. Σε ένα μη ισορροπημένο dataset, η μειοψηφική ομάδα είναι αυτή η οποία «απορροφά» ευκολότερα (ιδίως στα σύνορα μεταξύ των ομάδων) δείγματα της πλειοψηφικής, οδηγώντας στην πτώση της NMI.

Σε μια προσπάθεια οπτικοποίησης της επίδρασης των μη ισορροπημένων dataset τονίζεται ότι ο αλγόριθμος αυτός, με βάση της αρχή λειτουργίας του, επιδιώκει να τραβήξει μια γραμμή στην «μέση» των δεδομένων, δημιουργώντας clusters με ίδιο μέγεθος. Όταν τα clusters δεν έχουν τον ίδιο αριθμό δειγμάτων, ο αλγόριθμος -συχνά- «κόβει» και τοποθετεί ένα μέρος της πλειοψηφικής ομάδας στην μειοψηφική ομάδα.



Έτσι, παρόλο που ενδέχεται η πλειοψηφική ομάδα να είναι απολύτως καθαρή (pure) η μειοψηφική θα έχει «μολυνθεί» από τα σημεία της πλειοψηφικής, τα οποία ο αλγόριθμος λανθασμένα τοποθέτησε εκεί. Γι' αυτόν τον λόγο, η NMI μειώνεται σημαντικά.





DBSCAN

Παρακάτω παρουσιάζονται όλα τα πειραματικά αποτελέσματα τα οποία προέκυψαν από την μελέτη του αλγορίθμου DBSCAN.

Αρχικά, επιδιώχθηκε να γίνουν fine tuning οι παράμετροι eps και min_samples. Τα αποτελέσματα της παραπάνω διαδικασίας αποτυπώνονται στα παρακάτω διαγράμματα:





Από τα παραπάνω διαγράμματα καθίσταται σαφές ότι ο αλγόριθμος υποφέρει από σοβαρό underperforming.

Αρχικά, ξεκινώντας από τα 2 τελευταία διαγράμματα, προκύπτει ότι ο αλγόριθμος, στην συντριπτική πλειοψηφία των περιπτώσεων, αδυνατεί να ομαδοποιήσει τα δεδομένα σε 2 clusters (βλ. αριθμό εντός κάθε βούλας). Οι ελάχιστες περιπτώσεις όπου αυτό επιτυγχάνεται, χαρακτηρίζονται από σημαντικά χαμηλή τιμή των μετρικών αξιολόγησης, πράγμα που φανερώνει το underperforming του αλγορίθμου.

Επίσης, από την μελέτη των heatmaps, δεν προκύπτει κανένα ζεύγος παραμέτρων που δίνουν ικανοποιητικά υψηλές τιμές μετρικών αξιολόγησης. Αυτό, οδηγεί στην αδυναμία επιλογής παραμέτρων για την δημιουργία σχετικού μοντέλου.

Συνολικά, η απόδοση του αλγορίθμου χαρακτηρίζεται ως απογοητευτική, καθώς αποτυγχάνει -σχεδόν ολοκληρωτικά- να επιτύχει τον στόχο του.



Agglomerative Hierarchical Clustering

Παρακάτω παρουσιάζονται όλα τα πειραματικά αποτελέσματα τα οποία προέκυψαν από την μελέτη του αλγορίθμου Agglomerative Hierarchical Clustering.

Οι παράμετροι που χρησιμοποιήθηκαν στο μοντέλο είναι:

- `n_clusters=2`
- `linkage='ward'`

Οι τιμές των μετρικών αξιολόγησης, μετά την εκτέλεση του παραπάνω μοντέλου είναι:

- `ARI = 0.6886`
- `NMI = 0.5679`

Από τις παραπάνω πειραματικές τιμές προκύπτει ότι το μοντέλο δύναται να χαρακτηριστεί ως «μέτριο προς καλό». Φυσικά, οδηγείται σε ορισμένες αστοχίες, ωστόσο προβαίνει και σε αρκετές ορθές επιλογές.

Και πάλι όπως και η στην περίπτωση του K-Means, ορισμένοι λόγοι οι οποίοι ενδέχεται να επηρεάζουν αρνητικά την απόδοση του μοντέλου είναι οι εξής:

- Τα όρια μεταξύ των clusters δεν είναι απολύτως σαφή, αλλά υπάρχει υπερκάλυψη αυτών (overlapping).
- Η ανισορροπία μεταξύ των δειγμάτων του dataset.



ΣΥΜΠΕΡΑΣΜΑΤΑ

Παρακάτω παρουσιάζονται συνοπτικά τα συμπεράσματα τα οποία προέκυψαν από την παρούσα έρευνα.

Ακολουθεί ο συγκεντρωτικός πίνακας των τιμών των μετρικών των μοντέλων που χρησιμοποιήθηκαν:

Clustering Algorithm	ARI	NMI
K-Means	0.6766	0.5586
DBSCAN	-	-
AHC	0.6886	0.5679

Αρχικά, τονίζεται ότι κανένα ζεύγος παραμέτρων του DBSCAN δεν αξιολογήθηκε ως ικανοποιητικό και γι' αυτό δεν δημιουργήθηκε κάποιο μοντέλο. Έτσι, απουσιάζουν οι τιμές των μετρικών από τον παραπάνω πίνακα.

Αναφορικά με τους εναπομείναντες 2 αλγόριθμους, φαίνεται ο Agglomerative Hierarchical Clustering να είναι οριακά πιο αποδοτικός από τον K-Means.

Παρ' όλο που το μοντέλο AHC απαιτεί περισσότερη χρονική διάρκεια για να εκτελεστεί σε σχέση με το μοντέλο K-Means, η διαφορά αυτή αντισταθμίζεται από το γεγονός ότι ο AHC δεν απαιτεί fine tuning σε περιπτώσεις όπου είναι εκ των προτέρων γνωστός ο αριθμός των clusters, ενώ ο K-Means χρειάζεται. Αυτό έχει ως αποτέλεσμα ο συνολικός χρόνος που απαιτείται για τον ορισμό των παραμέτρων του μοντέλου (fine tuning) καθώς και για την εκτέλεσή του, είναι σημαντικά υψηλότερος στην περίπτωση του K-Means. Αυτό είναι ένα ασφαλές συμπέρασμα μόνο για datasets παρόμοια με αυτό που χρησιμοποιήθηκε στην παρούσα έρευνα. Με την αύξηση του μεγέθους του dataset, λογικά, αναμένεται αντιστροφή του παραπάνω συμπεράσματος.



ΠΡΟΤΕΙΝΟΜΕΝΗ ΜΕΛΛΟΝΤΙΚΗ ΕΡΕΥΝΑ

Παρακάτω παρουσιάζεται η προτεινόμενη μελλοντική έρευνα η οποία προτείνεται με βάση τα συμπεράσματα που προέκυψαν από τούτη την έρευνα.

Έτσι, προτείνεται:

- Προσπάθεια περαιτέρω οπτικοποίησης των δεδομένων για βελτίωση της ερμηνείας των πειραματικών αποτελεσμάτων.
- Αξιολόγηση των παραπάνω αλγορίθμων σε περισσότερα datasets.
- Αξιολόγηση περισσότερων αλγορίθμων σε διάφορα datasets.
- Ταξινόμηση δειγμάτων με βάση το clustering και σύγκριση με άλλους ταξινομητές μέσω supervised learning. Αυτό, δύναται να λειτουργήσει σαν μια επιπλέον μετρική αξιολόγησης των αλγορίθμων clustering.